

CAHIER DES CHARGES

Assistant Virtuel Intelligent pour l'Acquisition, la Qualification
et le Conseil en Crédit

Cadre : Stage de Fin d'Année (PFA)

Organisme d'Accueil : SOFAC Assurance – Siège Social, Casablanca

Périmètre : Direction des Systèmes d'Information

Profil d'Exécution : Badr Kandri – Data Scientist



Juin 2026

Table des matières

1	Axe Fonctionnel du Projet	3
1.1	Contexte, Problématique et Opportunités	3
1.2	Périmètre Fonctionnel de l'Agent Commercial	3
1.3	Architecture Fonctionnelle et Cinématique des Flux	3
2	Axe Technique et Choix Technologiques	4
2.1	Étape 1 : Ingestion, Scraping Avancé et Structuration du Corpus	4
2.2	Étape 2 : Distillation de Connaissances (Knowledge Distillation)	4
2.3	Étape 3 : Fine-Tuning Local avec Architecture PEFT/LoRA	4
2.4	Étape 4 : Implémentation du RAG (Retrieval-Augmented Generation)	4
2.5	Étape 5 : Orchestration Agentique de la Conversation	5
3	Roadmap Opérationnelle de Réalisation	5
4	Contraintes, Sécurité et Critères de Succès	6
4.1	Sécurité et Confidentialité Souveraine	6
4.2	Critères d'Évaluation et KPIs de Succès	6

1. Axe Fonctionnel du Projet

1.1. Contexte, Problématique et Opportunités

SOFAC propose à ses prospects et clients une interface en ligne permettant de simuler et de fixer des rendez-vous pour différents types de produits de crédit. Cependant, le parcours utilisateur actuel souffre de frictions majeures :

- **Données incomplètes ou insuffisantes** : Les utilisateurs omettent fréquemment des informations critiques nécessaires à l'analyse préliminaire de leur solvabilité.
- **Sélections arbitraires** : L'utilisateur choisit parfois des options au hasard pour accélérer le processus, faussant la qualification du besoin.
- **Perte de conversion** : L'absence d'un conseiller interactif en temps réel au moment de la simulation mène à un taux de rebond élevé et surcharge les équipes physiques avec des rendez-vous mal qualifiés.

L'objectif fonctionnel est de déployer un **Agent Commercial Virtuel (Chatbot)** capable de mener une discussion fluide, d'extraire dynamiquement les informations manquantes, de comprendre le besoin de crédit profond, et de négocier l'offre commerciale la plus adaptée.


1.2. Périmètre Fonctionnel de l'Agent Commercial

L'agent virtuel devra remplir quatre rôles fonctionnels séquentiels :

1. **Formulaire Dynamique et Conversationnel (Slot Filling)** : Remplacer le formulaire statique par une discussion où l'agent valide et extrait les variables sans que l'utilisateur n'ait l'impression de subir un interrogatoire.
2. **Analyse du Besoin Métier** : Interpréter le projet de l'utilisateur pour identifier les contraintes implicites.
3. **Présentation de l'Offre Initiale** : Formuler une proposition commerciale transparente basée sur le catalogue officiel de la SOFAC.
4. **Module de Négociation et d'Ajustement** : Si l'offre ne convient pas (mensualités trop élevées, durée trop longue), l'agent doit être capable de proposer de manière itérative des alternatives adaptées (allongement de la durée, bascule vers un autre produit).

1.3. Architecture Fonctionnelle et Cinématique des Flux

Le système s'articule autour d'une boucle d'interaction fermée garantissant la pertinence des réponses :



2. Axe Technique et Choix Technologiques

Pour des raisons strictes de confidentialité et de souveraineté des données financières au sein du siège de la SOFAC, l'intégralité de l'architecture logicielle doit être déployée **localement (On-Premise)** et s'appuyer sur un modèle de langage de taille raisonnable (*Small Local LLM*), hautement optimisé.

2.1. Étape 1 : Ingestion, Scraping Avancé et Structuration du Corpus

La base de connaissances initiale est constituée des règles métiers, barèmes, et structures de simulation extraites depuis la plateforme Crediz de SOFAC.

- **Extraction Source** : Collecte brute des structures de pages et règles de calcul depuis le lien du service de crédit en ligne.
- **Pipeline de Structuration** : Utilisation d'un modèle de langage avancé externe (Claude) en tant que *Parser* de données de haut niveau. Ce modèle reçoit le flux brut extrait, isole les règles de décision, nettoie le bruit HTML/JS, et structure l'information sous forme de documents Markdown propres et schémas JSON standardisés.
- **Livrable Technique** : Un dossier de données structurées (*Clean Knowledge Base*) exempt d'hallucinations, prêt pour l'indexation.

2.2. Étape 2 : Distillation de Connaissances (Knowledge Distillation)

Afin d'obtenir un modèle local performant et économique, la technique de distillation est privilégiée.

- **Principe** : Transférer les capacités de raisonnement logique et de structuration d'un modèle "Enseignant" (*Teacher* de grande taille) vers un modèle "Élève" (*Student* local de type 7B ou 8B paramètres, tel que Mistral-7B ou Llama-3-8B).
- **Application** : Génération d'un dataset d'entraînement synthétique combinant des dialogues financiers types, des stratégies de relance commerciale et des formulations de négociation d'offres de crédit.

2.3. Étape 3 : Fine-Tuning Local avec Architecture PEFT/LoRA

Le modèle local distillé doit adopter le comportement d'un conseiller financier certifié SOFAC.

- **Technologie** : *Parameter-Efficient Fine-Tuning* (PEFT) via la méthode **LoRA** (*Low-Rank Adaptation*).
- **Objectif technique** : Geler les poids du LLM de base et entraîner uniquement des matrices de rang inférieur. Cela permet de réduire l'empreinte mémoire VRAM lors de l'entraînement et de spécialiser le modèle dans l'extraction d'entités financières (Slot Filling) et la gestion des structures de dialogue sans risquer l'oubli catastrophique.

2.4. Étape 4 : Implémentation du RAG (Retrieval-Augmented Generation)

Le fine-tuning n'est pas adapté au stockage de données factuelles dynamiques (les taux d'intérêt et les offres de crédit pouvant changer fréquemment), un système RAG local est implémenté.

- **Modèle de Embedding** : Utilisation d'un modèle d'embedding open-source local (ex : *bge-large-fr* ou *all-MiniLM-L6-v2*) pour vectoriser le corpus structuré à l'étape 1.
- **Base de Données Vectorielle** : Déploiement local d'une base de données vectorielle (ex : *ChromaDB* ou *Faiss*) pour stocker et indexer les vecteurs.
- **Mécanisme** : À chaque message de l'utilisateur, le système extrait le contexte pertinent du catalogue de crédit SOFAC et l'injecte dans le prompt du LLM local, garantissant des calculs et des propositions commerciales 100% exactes et à jour.

2.5. Étape 5 : Orchestration Agentique de la Conversation

Pour gérer la logique commerciale (vérifier si une donnée est manquante, décider quand proposer une offre alternative), un framework d'orchestration agentique local est mis en place.

- **Outils d'orchestration** : Utilisation de bibliothèques légères d'agents autonomes (*Agno*).
- **Logique d'exécution** : L'agent utilise le *Tool Calling* local pour interroger des scripts Python de calcul de mensualités officiels basés sur les données extraites, assurant une parfaite étanchéité entre la génération de texte et la logique de calcul financier.

3. Roadmap Opérationnelle de Réalisation

Phase	Période	Objectifs Techniques
Phase 1 : Extraction & Structuration	Semaine 1	➤ Utilisation de Claude pour le parsing et l'extraction d'échantillons (<i>samples</i>). ➤ Génération du <i>Synthetic Data</i> par un LLM mature basé sur (<i>les samples</i>).
Phase 2 : Fine-Tuning	Semaines 2 – 3	➤ setup l'environnement d'entraînement PEFT/LoRA. ➤ Fine-tuning d'un petit modèle local abordable (<i>Small Local LLM</i>) sur le jeu de données synthétique.
Phase 3 : RAG & Orchestration	Semaines 4 – 5	➤ Choix et déploiement de la base vectorielle locale. ➤ Implémentation de la mémoire de l'agent. ➤ Connexion aux outils Python de calcul de crédit.
Phase 4 : Optimisation Locale	Semaines 6 – 8	➤ Quantification du modèle. ➤ Optimisation de la latence au tokens. ➤ Tests d'intégration et de robustesse des prompts.
Phase 5 : Déploiement	Semaines 9 – 10	➤ Évaluation des réponses par les experts métiers SOFAC. ➤ Audit de sécurité. ➤ Livraison de l'interface et documentation finale.

4. Contraintes, Sécurité et Critères de Succès

4.1. Sécurité et Confidentialité Souveraine

- **Zéro Fuite de Données** : Aucune Donnée Identifiable Personnellement (PII) issue des simulations clients ne doit transiter par des réseaux ou APIs externes après la phase d'ingestion initiale. Le modèle en production tourne à 100% en circuit fermé au siège.
- **Gouvernance du Code** : L'ensemble des scripts de fine-tuning et d'ingestion de données doit être documenté, versionné et auditable par le pôle sécurité de la SOFAC.

4.2. Critères d'Évaluation et KPIs de Succès

Le succès du déploiement de l'agent virtuel sera mesuré selon trois axes précis :

1. **Taux de Complétion des Dossiers (> 85%)** : Pourcentage de sessions de chat aboutissant à un profil utilisateur 100% qualifié (aucune donnée manquante pour le conseiller physique).
2. **Pertinence Commerciale (> 95%)** : Alignement strict entre les offres de crédit proposées par le modèle local et les barèmes réels stockés dans la base vectorielle (zéro hallucination financière).
3. **Performance Système (Latence < 10 secondes)** : Temps de réponse moyen pour maintenir une dynamique de conversation fluide et naturelle pour l'utilisateur.